Week 6 多模态桌面智能体实验报告

系统 v2.0.0 高级功能与鲁棒性优化

2026 年 10 月 26 日 Australia/Sydney

1 交付范围与主要结果

本版按项目大纲的 Week 6 四项要求整理工程交付。自动拆解采用整体指令约束下的逐动作在线规划，在专用四阶段窗口完成两组固定目标，其中一组包含真实瞬态审阅拒绝后的恢复。完整 CPU 回归为 3027 项通过、0 失败，pytest 535.12 秒，封装墙钟 566.027 秒，真实 exit 0；244 份文件的 before、after 与当前 SHA 完全一致。

大纲要求	本版实现与验证范围	证据
自动拆解与分步执行	当前画面下一动作规划，输入后重观察，固定调用方目标	正常 017 与瞬态 015 按原约束完整通过
错误检测与自动重试	新观察重规划，共享额度，未知派发停止	真实审阅拒绝恢复及 11 场景模拟
UI 识别准确率与速度	screen 双语 OCR 与同帧轮廓去重，分开测量代价	6 帧冻结留出与 100 组配对计时
实时监测与日志	根终态和子任务逐输入日志，只读检查进程身份	两个正向批次原状态与输入回执

层次化语义子任务生成与子任务依赖管理未实现。CALLER_GOAL 是本地执行容器，模型根据完整目标生成下一动作，并未生成经验证的语义子任务序列。本周结论适用于受控专用窗口及冻结图像，不能推出任意应用的复杂任务成功率。大纲第三页的 Week 7 综合任务集、跨应用与分辨率评估和竞品对比另行开展。

正常 017 为 ALPHA 与 GREEN，4 个输入、4 次规划、4 次 HTTP，运行 652.750 秒；瞬态 015 为 BETA 与 BLUE，5 个输入、5 次规划、5 次 HTTP，运行 275.703 秒。运行器、独立应用终态、逐项输入归因及源码未变均通过。原始失败和早期中断分别保留，不合并计算开发过程成功率。

留出集 screen 配置识别 46/48 个标签，精确率、召回率与 F1 均为 95.83%；同双语资源的原始配置识别 30/48 个。screen 整帧处理中位耗时增加 9.75%。轮廓去重使固定四图 UI 提取中位耗时减少 15.51%，没有证明整个智能体普遍加速。

开发在 codex/week6-delivery 分支进行。本周不新增训练或消息发送；Week 5 C11 权重、原训练、质量结果及资源补测结论独立保留。报告日期为 2026 年 10 月 26 日 Australia/Sydney，原运行时间戳及其显式时区偏移保持不变。

2 整体指令约束下的滚动动作规划

CLI 的 --instruction 入口默认采用 rolling_actions。调用方提供整体任务和不可由模型改写的最终 expect_text、forbid_text；模型读取当前截图和候选元素，提出至多一步原生动作计划。执行器按新帧解析当前目标，输入后重新观察。如果调用方目标尚未满足，运行器把失败分类与剩余额度带入下一次规划。

Python AutomaticWorkflowRunner API 默认保留 observed_departure 兼容入口；CLI 可用 --automatic-protocol observed_departure 显式选择旧模式。旧流程的 marker 选择、原模型检查与 A 派生进展契约只按各自历史版本解释，后续真实正向验收使用滚动动作协议。

当前协议为 week6.rolling_actions.v2。输入前的 rolling_compilation.json 保留完整原请求、CALLER_GOAL 本地容器、独立 FINAL 规则和共享限额，明确 gate_on_step_verification=false。这个设置使模型自写的 step expected_result 作为诊断预测，保留原始 passed、failed 与 inconclusive。每次规划仍硬限 max_steps=1，结束这一步即由既有 TaskRunner 重新观察并检查调用方最终规则。

单步上限约束每次计划，整个任务可在预算内多次规划和输入。模型预测未匹配时不会因自造句子挡住已经满足的调用方目标；真正执行失败、未知派发、取消和超时的原早退分支继续有效。未满足调用方规则时继续重规划；容器结束后，还必须使用另一张独立新帧检查同一最终规则。

原 --workflow 入口保留调用方显式定义的 1 至 32 个有序阶段，与整体 instruction 互斥。其逐阶段严格检查保持原行为。滚动路径没有模型生成的层次结构或依赖图，也没有语义已完成阶段台账；固定容器和动作数不能解释成已完成语义子任务数。

模型输出 finish、自然语言 reason、派发成功或局部 step 诊断均不能独立证明整体成功。所有原回复、parsed plan、当前画面、解析动作与最终验证分别保存。已有运行目录会被拒绝，旧日志不能触发自动恢复；默认 dry-run 不改变应用状态，真实 CLI 执行仍需交互确认。

3 失败恢复与运行状态

目标缺失或明确失败后，重规划通过 context.recovery 获得失败分类、最多五个动作结果、累计和剩余动作数及剩余时间。反馈不携带旧坐标、输入内容或模型原文。运行器重新观察并解析当前目标，避免直接重用旧帧位置。

动作、规划调用、实际 HTTP 和单调时钟时限全程共享；失败与恢复也消耗额度。OpenAI 兼容客户端按 httpx 实际派发事件计数，关闭 SDK 隐式重试，请求超时缩至剩余时限，返回过晚的结果会被拒绝。自动入口拒绝无法明确计数的 LangChain transport。格式重试与规划调用、HTTP 数量分别记录。

派发前写入 dispatch_intents.jsonl，意图不证明输入发生。进入执行器后异常退出且无完整 ActionResult 时，该次记入 unconfirmed_action_attempts 并停止自动重试。已确认动作数此时只是实际输入数量的下界。派发前观察失败可保持未知次数为 0，两种情况在 014 与 016 分别保留。

根目录保留原子 run_status.json 和追加 status_events.jsonl，记录整体阶段与真实终态；逐输入动作、规划和恢复细节主要在 workflow/001_CALLER_GOAL 子目录。根状态未必逐步更新，不能用根动作 0 解释子任务没有输入。状态记录包含 PID、进程身份、限额和经过时间，不保存任务正文、输入或坐标。

scripts/week6_status.py 只使用标准库，只读核对快照、事件序列及进程身份。缺失、损坏、过期、进程消失、PID 复用或暂不可读分别诊断。finished 表示终态记录可信，成功与否仍须读取 task_status。长模型调用没有新阶段事件时，过期状态不能被解释为进程退出。

模型返回、监测及意图写入后继续检查时限与前台身份。未知派发后不重放，不完整计数不得作为完整验收；取消摘要只读取有效步骤和恢复记录，损坏行注明，原日志保留。正常 017 和瞬态 015 均保留可信 active 与 succeeded 终态，以及独立真实 owner 退出收据。

4 感知优化与冻结实验

候选框优化只处理当前帧。代码合并重复边框、缓存同帧几何量，先做面积筛选再计算交集，并保留原边缘检测、OCR 排除、候选预算与排序规则。此前四张 960×640 合成图的 100 组交替顺序配对中，有序候选的坐标、中心、来源和置信度完全一致。

该组 UI 提取中位耗时由 14.421 降至 12.185 ms，减少 15.51%。浅色、深色、密集与细边框图分别为 8.569→8.417、8.003→8.220、22.238→16.912、22.631→16.150 ms；深色图略慢。顺序测得的热观察总时间为 221.848→228.817 ms，增加 3.14%，不支持整帧普遍加速结论。

新增准确率实验在优化前冻结 12 张合成图、96 个可见标签、72 个矩形控件、字体和图片哈希。开发集与留出集各六图，文字、布局、尺寸及视口不同。方法在开发集选择后冻结，再进行一次正式留出评价；生产 OCR 不接收标注、期待文字或图片名称。

screen 配置在单次当前帧 OCR 中做深色背景归一化、全局对比度拉伸、长横竖边框抑制、2 倍 Lanczos 放大，使用 Tesseract PSM 11/OEM 1；随后连接同一行的中日韩字符间空白，并把坐标向外取整、映射和裁切到原图。轮廓提取继续使用原图，不缓存旧帧位置。

三个对照组分别为原始英文、相同英中语言资源的原始配置、相同资源的 screen 配置。这样可以区分增加中文资源和算法处理的影响。文字按常规空白归一化后完全匹配，且一对一框匹配 IoU≥0.5；未匹配输出计为误检。矩形控件另用一对一 IoU≥0.8。

5 留出准确率与处理代价

留出配置	TP FP FN	精确率	召回率与 F1	整帧中位 ms
原始英文	28 4 20	87.50%	58.33% 70.00%	199.343
原始英中双语	30 11 18	73.17%	62.50% 67.42%	342.302
screen 英中双语	46 2 2	95.83%	95.83% 95.83%	375.676

准确率每张图只计一次，共 48 个留出标签。每配置每图运行三次、交替顺序，54 份结果全部保留，重复结果一致；这些重复标签不能当成 144 个独立样本。时延采用全部重复记录的中位数，范围是 PNG 解码、真实 CPU OCR 和候选提取，不含操作系统截屏、模型规划或动作执行。

screen 配置英文为 30/30，中文为 16/18。相较同双语资源原始配置，召回率增加 33.33 个百分点，处理中位耗时增加 9.75%；相较原始英文配置，召回率增加 37.50 个百分点，耗时增加 88.46%。三个配置都找出 36/36 个矩形控件，多余轮廓分别为 21、9、2；该指标仅覆盖本实验完整标注的矩形控件。

三组整帧最近秩 p95 分别为 273.393、372.819、420.675 ms，每组 n=18，是六张图各三次的相关重复。该统计包含全部重复，没有排除慢记录；因样本少且相关，不能解释为桌面任务时延分布。

开发记录也保留：001、002 批次在路径处理阶段失败，未完成 OCR 对比；003 批次仅放大后，screen 识别 33/48、精确率 70.21%；004 加入通用边框抑制后识别 44/48、精确率 93.62%，据此冻结。留出评价后未按失败标签调参。实验没有导入 GPU 框架或训练模型。

6 真实截图验证与识别限制

冻结参数后另取一张实际专用窗口截图，先手工视觉标注中心区域的五个英文标签及两个按钮，再对完整 2560×1600 图片运行三个配置、每组重复三次。标注区域只用于计分，不裁切 OCR 输入；源码、图片、标注及探测脚本前后哈希一致。

实际截图配置	区域标签	区域按钮	整帧中位 ms
原始英文	5/5 无误报	2/2	428.466
原始英中双语	5/5 无误报	2/2	577.626
screen 英中双语	5/5 无误报	2/2	836.893

这张简单英文画面没有准确率增益，screen 处理成本更高。区域外的其他 UI 未完整标注，整帧精确率保留为缺失值。该源运行另有未解释的外部输入事件，不能作为智能体执行成功证据；本实验只评价保存的像素，不运行模型或桌面动作。

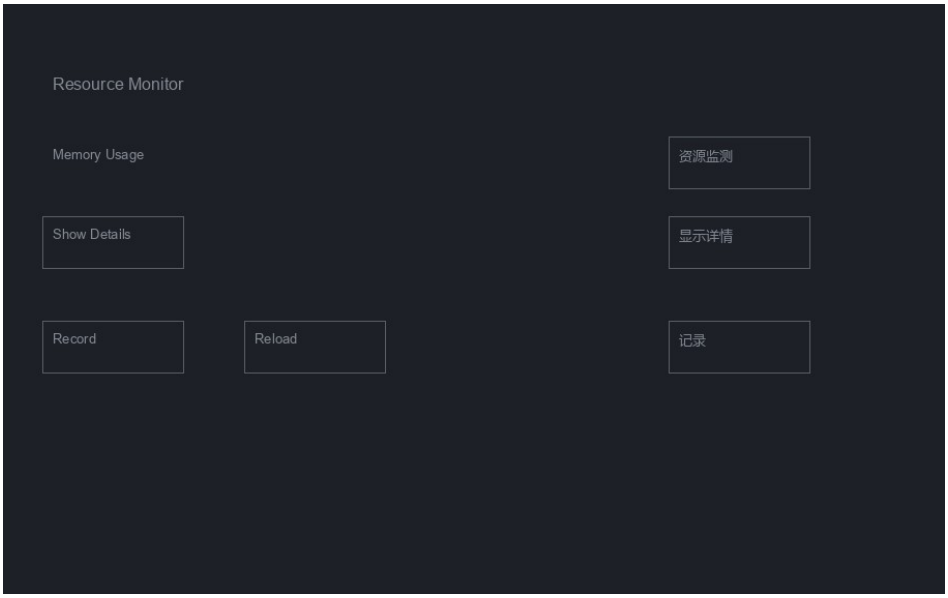


图 1 合成留出图中的资源监测和显示详情仍未准确识别 三次错误均保留

真实截图只有一个独立画面、五个标签，不能证明真实桌面分布上的准确率提升。合成留出集的两个中文错误也没有按期待标签修正。默认 native 配置继续保留，screen 由调用方显式选择。

7 确定故障下的运行行为

故障演示真实调用 `WorkflowRunner`、`TaskRunner`、`ActionAdapter`、`Verifier` 和 `TaskRecorder`。观察、规划、执行与时钟由确定状态机代替，执行器只改内存，不调用 OCR、模型或桌面。最终第五批 11/11 场景、218/218 行为核对通过，墙钟 10.569 秒。失败或阻止终态符合预期时，也计为行为核对通过。

场景	整体状态	确认调用	未确认	规划	恢复
无故障三子目标	succeeded	3	0	3	0
第二目标短暂缺失	succeeded	3	0	4	1
一次明确执行失败	succeeded	4	0	4	1
持续失败至规划上限	failed	3	0	3	1
共享动作额度耗尽	blocked	2	0	2	0
返回时总时限耗尽	timed_out	1	0	1	0
第二阶段规划中取消	cancelled	1	0	2	0
子目标全过而总体未过	failed	3	0	3	0
dry-run	dry_run_completed	3	0	3	0
消息工作流	rejected	0	0	0	0
执行结果未知	failed	1	1	2	0

已确认调用沿用生产 `action_count`，包括取得完整结果的失败调用及 dry-run 校验，并不等于成功执行数。未知执行场景中，执行器改变状态后抛出异常，已确认数为 1、未确认数为 1，`accounting_complete=false`，没有继续重放。

目标移动场景对照派发当时的帧，恢复使用新位置，第一子目标仅执行一次。所有场景保留轨迹、子任务日志、恢复记录、检查点、期望与实际值及源码快照；源码前后哈希一致。已有目录拒绝检查没有改变原批次字节。模拟结果用于解释运行机制，真实窗口结果另列。

8 真实窗口验收方法与结果

验收使用专用离线 Tk 窗口、整体自然语言指令和调用方最终文字规则。模型读取真实截图、CPU Tesseract 文字和当前帧候选；独立应用状态及事件文件仅供验收对照，不作为模型输入。任务要求先选项目、再选主题、审阅、提交，最终同时显示正确项目、主题和 LOCAL COMPLETE。

生产规划器、动作适配器、TaskRunner、WorkflowRunner 与验证器按真实模型回复运行。输入经 Sky 桥接，保留生产适配器解析的坐标，并在派发前重新观察、限定专用窗口，只接受单击或双击。桥接的逐次起止和返回结果用于归因；该实验没有通过 stock PyAutoGUI 执行器派发，不能替代其任意应用验证。

新源码实际批次	目标及条件	HTTP 规划 输入	运行秒	严格整体结果
正常 017 10 月 26 日	ALPHA GREEN	4 4 4	652.750	succeeded 全部核验通过
瞬态 015 10 月 25 日	BETA BLUE 首次审阅拒绝	5 5 5	275.703	succeeded 全部核验通过

两批均为 qwen2.5vl:7b、本机 Ollama 端点，温度 0、max_tokens 2200、transport 重试 0；限额均为 12 次动作、12 次规划、24 次 HTTP 及 1200 秒。源码 SHA 为 706d98f6156f01224c3fcb99b971623553f91e732249818c029b46665efd6940，90 份生产与实验源码在各批次前后未变。真实 owner 子进程均 exit 0，未知派发 0，accounting_complete=true，completion_basis=executed_caller_goal。

正常四次语义转换分别唯一对应 input_001 至 004。瞬态保留 review_rejected 后重新观察、重新规划及 review_accepted，五次语义事件分别对应 input_001 至 005。不同语义转换不能共用一个双击回执；应用中的 400 ms 跨页防重入属于实验环境修复，不计模型质量提升。

瞬态拒绝来自应用审阅层，两批所有 ActionResult 均 success、已知执行器失败数均为 0；真实恢复证明 UI 拒绝后的新观察重规划，执行器失败分支另由 CPU 场景验证。

正常原 step 诊断 4 passed。瞬态为 4 passed、1 failed：提交后的画面没有模型写的 Commit locally action completed，原 failed 保持不变；调用方规则与独立 final 仍通过。审阅被拒那一步也因宽松词匹配记为 passed，所以局部 step 诊断不等于语义成功。所有原回复、检查、失败及最终判据可分别追溯。

耗时包含模型、截屏、OCR、激活与桥接等待，不能称纯 GPU 计算或无人值守稳态时延。两组固定目标不足以形成一般任务成功率，也未比较 3b 与 7b 模型优劣。

9 真实窗口开发记录

初始 qwen2.5vl:3b Q4_K_M 另在三张保存合成图上进行 3 次规划、5 次 HTTP：两个唯一目标对照正确，双同名按钮猜选左侧；三个最终计划均省略提示要求的 finish，两个条件首次状态字段触发格式重试。它没有 OCR 或桌面执行，不是任务成功率。

正式验收前的 001 至 007 批次分别暴露了输出长度、桥接能力、前台条件及输入归因问题。独立只读审计保留原记录与哈希，核对 636 份原始文件并另存 160 份结构化副本，输入和副本在审计前后未变。审计不运行推理或桌面输入。这些开发记录没有形成可比较的完整任务评分集，不计算合并成功率。

批次	原始可观察事实	处理与归类
001	3b 规划回复达到 2200 token 截断，无输入	输出失败，整体 blocked
002	7b 请求双击，最初只支持单击的桥接返回 5 次完整拒绝	桥接能力不匹配，人工停止
003	应用发生 4 次阶段转换，却没有 Sky 输入回执	外部输入归因异常，不计完成
004	专用窗口不是稳定前台，动作数 0	安全前置检查 blocked
005	约 90 秒未获窗口激活回执，模型调用 0	激活超时，整体 failed
006	回执明确报告专用窗口不存在，模型调用 0	恢复后的环境缺失，failed
007	一次双击触发项目和主题两次转换，相隔 149.975 ms	跨页误触风险，停止且未确认完成

002 的原操作说明退出码保留为未知，外层 shell 后续另观测到 exit 1；两者来源不同，不回填原记录。该说明在当时记下三次拒绝，完整步骤日志则保留五次拒绝，两份证据均保留。005 的 Esc 原因来自当时操作说明，原始日志直接证明的是激活超时，不单凭日志推断按键。

007 只有一个成功输入回执，却产生两个语义转换，不能证明模型分别规划并执行了两阶段。后续专用窗口增加 400 ms 跨页防重入；验收要求每个语义转换分别对应不同输入回执。此项修复属于实验环境，不能计作模型识别或规划质量提升。

多轮自动工作流也移除了冗余父级监测，避免局部工作流计数重置误导根进度。真实状态及原始步骤继续保留，正式验收另用新目录。审计依据为 `live_development_audit_20261024/summary.json`，源运行中缺少的摘要和退出码保持未知。

10 后续失败与保存图诊断

008 以后各尝试按独立目录保留。下表区分模型输出、进程停止、环境等待和未归因的应用终态；实际 owner 退出码不替代运行器完成判定。

批次	计数与原始结果	解释
正常 008	2 输入 6HTTP 776.391 秒 failed	两阶段归因通过，后续激活超时
正常 009	2 输入 7HTTP 276.563 秒 failed	第三轮三次提案检查已满足，未审阅
正常 010 及 011	各 0 输入 1HTTP 34.391 与 38.422 秒	needs_clarification，非用户缺信息结论
正常 012 旧源 v1	4 输入 4HTTP 253.657 秒通过	仅旧源历史成功，不替代 v2 验收
瞬态 013	6 已知输入 7HTTP 真实 exit15	受控停止，无完整运行验收
正常 014	2 已知输入 1 未知 3HTTP failed	桥接请求到期，无完整第三回执
正常 016	3 输入 0 未知 4HTTP 397.781 秒 failed	提交无输入归因，随后激活超时

013 的应用已经到达完成画面，但模型提交预测句子未出现，原 step failed 后又提出完成标签动作。六次输入有完整结果，第七计划已保存而无后续回执；核验实际 PID 及创建时间后受控停止。原 child 摘要只包含第六轮的临时计数，native 与 transport 记录为七次，single-step 恢复未完成；不补写 acceptance 或成功退出码。

014 原运行器在第三次执行器调用后无完整结果，记 1 个 unconfirmed，禁止自动重放；操作记录另报告桥接 Expired input。016 的独立应用终态通过，但 local_commit 事件不在三个保存输入回执区间内，来源未知。第四个 Commit locally 计划在派发前因激活回执缺失而停止，ActionResult 为空，后续重规划同样未启动。不能推断额外智能体输入、自动提交或外部操作者。

保存图诊断也完整保留。旧生产分解 3 次、显式多轮 2 次、字段语义 2 次、新合取版本 1 次与 schema 示例 1 次，共 9 次 HTTP；旧字段组合存在合取误拦，后两次结构允许仍有后态可实现性疑点。之后另有 8 个明确命名的单请求归档探针：三个 schema 探针、一个动作规划、一次原请求无图对照及三次 goal-blind marker 诊断。ready、局部正确 ALPHA 计划和模型 reason 均没有被计作桌面成功。

这些保存图探针均无新截屏、输入或任务执行；不同方案及失败条件不合并计算成功率。旧 marker 路径未证明稳定产生可执行语义阶段，当前正向证据只支持整体指令下的滚动动作规划。当前参数没有按留出标签或失败应用日志回填识别结果。

11 回归验证与历史保留

最新完整回归选取 results/release_validation_completed_20261026_006/validation.json。完整 CPU 回归为 3027 项通过、0 失败，pytest 535.12 秒，封装墙钟 566.027 秒，真实 exit 0；244 份文件的 before、after 与当前 SHA 完全一致。最终 tested_source_pins_before、after 和当前文件须完全一致，原 stdout、真实退出码、封装墙钟和 Ruff 结果分别保留，不把收集数拼成通过数。

完整检查批次	通过	失败	pytest 秒	退出码
第一阶段历史检查	2667	6	587.29	1
10 月 24 日首轮	2812	16	470.14	1
第二批	2837	0	439.53	0
第三批	2840	0	437.19	0
原交付第四批	2840	0	443.05	0
完善第一批	2916	1	437.36	1
完善第二批	2917	0	585.67	0
完善第三批	2917	0	606.57	0
full004 历史	2924	0	485.59	0
full005 历史	2927	0	428.96	0
当前 full006	3027	0	535.12	0

第一阶段六项编码失败在 UTF-8 修复后仅复测六项，6 通过、7.67 秒，当时没有一次全量通过。本轮最早 16 项失败涉及监测初始化、计时兼容、前台计数、版本断言与 Windows 文件替换。267 项定向检查曾 266 通过、1 失败；监测 51 项 2.66 秒及 OCR141 项 4.01 秒分别保留，不拼接为全量结果。

完善第一批唯一失败是 README 仍写 2840 而收集 2917。第二批虽全部通过、封装 591.059 秒，但两份实验脚本变化，tested_sources_unchanged=false；src、tests、configs、pyproject 未变。第三批封装 612.299 秒、源码未变；full004 封装 488.844 秒，full005 封装 431.515 秒，均作为旧阶段，不替代新 v2。

滚动 v2 的 191 项针对检查、23 项独立 CPU 反例及 3027 项 collect-only 均有对应原件，前两者只说明局部验证，收集检查不代表执行通过。完整回归只能引用本轮实际新源码结果。原 full004/full005 待完成稿、旧 DOCX、PDF 和先前源码包保留，各历史日期的结论不覆盖。

12 复现入口与证据

在仓库根目录先验证整体请求及调用方最终规则，该步骤不调用模型或桌面：

```
python scripts/week6_agent_cli.py --instruction "Complete the local task" --expect-text `
  "Expected final marker" --validate-only
```

默认 CLI 整体入口为 rolling_actions，Python API 默认 observed_departure。固定有序工作流仍用--workflow。默认 dry-run 会观察并调用模型，真实执行添加--execute 后仍需交互终端逐计划确认，没有--yes。screen 双语 OCR 须显式选择 configs/week6_accuracy.yaml，并按 Week6 使用说明 设置本机语言资源。

逐输入状态读取子目录；根目录用于整体生命周期和终态。完整检查命令：

```
python -S scripts/week6_status.py --run-dir `
  outputs/week6/your_run_id/workflow/001_CALLER_GOAL
$env:PYTHONUTF8 = "1"
$env:PYTHONIOENCODING = "utf-8"
python -m pytest -q
python -m ruff check src tests scripts
```

感知配对数据见 原感知实测，冻结准确率见 留出实验说明。真实像素数据为 perception_accuracy_live_20261024/external_001/summary.json；模拟为 robustness_20261024_attempt005/summary.json，早期模型为 model_recovery_20261024_001/。

真实正向原件为 live_auto_20261026_normal_017/acceptance.json 及 live_auto_20261025_transient_015/acceptance.json。每批保留 rolling_request/compilation、原生计划、HTTP 事件、前后截图、步骤、原 step 诊断、独立 final、应用事件及 owner 退出收据。各类历史开发失败在原目录保留；001 至 007 的审计见 live_development_audit_20261024/summary.json。

最终回归来源固定为 release_validation_completed_20261026_006/validation.json。交付检查覆盖同一 completion 原字节、最终页图、数字与链接，以及源码、wheel 和打包字节；结果由随包校验清单记录。本版按上述受限工程范围闭合实现与证据；报告和分发文件按独立生成与发布清单核验。

当前结论仅覆盖上述工程范围。层次化语义子任务、依赖管理和任意应用成功率未实现或未测；跨应用、分辨率及竞品比较属于 Week 7。screen 识别效果与处理代价分别报告，不承诺整个智能体更快。本机离线实验不新增消息发送。